

Universidad del Valle de Guatemala  
Departamento de Matemática  
Licenciatura en Matemática Aplicada

**Estudiante:** Rudik Roberto Rompich  
**E-mail:** [rom19857@uvg.edu.gt](mailto:rom19857@uvg.edu.gt)  
**Carné:** 19857

MM2036 - Estadística Matemática - Catedrático: Paulo Mejía  
23 de mayo de 2021

---

## Parcial 4

Instrucciones: Resuelva los siguientes problema. Favor hacer la solución en latex y cargar el archivo latex y pdf en la tarea de Canvas. Para la resolución de los problemas, se utilizará el libro de Wackerly et al. (2014).

### 1. Problema 1

Sea  $Y_1, Y_2, \dots, Y_n$  una muestra aleatoria de una distribución normal con media  $\mu$  y varianza 1.

#### Definición 4.8 - Distribución Normal

A random variable  $Y$  is said to have a normal probability distribution if and only if, for  $\sigma > 0$  and  $-\infty < \mu < \infty$ , the density function of  $Y$  is

$$f(y) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(y-\mu)^2/(2\sigma^2)}, \quad -\infty < y < \infty$$

1. a) Demuestre que  $\bar{Y}$  es un estimador suficiente para  $\mu$ .

*Solución.* Comenzamos definiendo al estimador suficiente como:

#### Teorema 9.4 - Estimador suficiente

Let  $U$  be a statistic based on the random sample  $Y_1, Y_2, \dots, Y_n$ . Then  $U$  is a sufficient statistic for the estimation of a parameter  $\theta$  if and only if the likelihood  $L(\theta) = L(y_1, y_2, \dots, y_n|\theta)$  can be factored into two nonnegative functions,

$$L(y_1, y_2, \dots, y_n|\theta) = g(u, \theta) \times h(y_1, y_2, \dots, y_n)$$

where  $g(u, \theta)$  is a function only of  $u$  and  $\theta$  and  $h(y_1, y_2, \dots, y_n)$  is not a function of  $\theta$ .

$$\begin{aligned}
L(y_1, y_2, \dots, y_n | \mu) &= L(y_1 | \mu) \times L(y_2 | \mu) \times \dots \times L(y_n | \mu) \\
&= \frac{1}{\sigma \sqrt{2\pi}} \exp \left[ \frac{-(y_1 - \mu)^2}{(2\sigma^2)} \right] \times \frac{1}{\sigma \sqrt{2\pi}} \exp \left[ \frac{-(y_2 - \mu)^2}{(2\sigma^2)} \right] \times \dots \times \\
&\times \dots \times \frac{1}{\sigma \sqrt{2\pi}} \exp \left[ \frac{-(y_n - \mu)^2}{(2\sigma^2)} \right] \\
&= \frac{1}{\sigma^n (\sqrt{2\pi})^n} \times \exp \left[ -\frac{1}{2\sigma^2} \left( \sum_{i=1}^n (y_i - \mu)^2 \right) \right] \\
&= \frac{1}{\sigma^n (\sqrt{2\pi})^n} \times \exp \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i^2 - 2y_i\mu + \mu^2) \right] \\
&= \frac{1}{\sigma^n (\sqrt{2\pi})^n} \times \exp \left[ -\frac{1}{2\sigma^2} \left( \sum_{i=1}^n y_i^2 - 2 \sum_{i=1}^n y_i\mu + \sum_{i=1}^n \mu^2 \right) \right] \\
&= \frac{1}{\sigma^n (\sqrt{2\pi})^n} \times \exp \left[ -\frac{1}{2\sigma^2} \left( \sum_{i=1}^n y_i^2 - 2n\bar{y}\mu + n\mu^2 \right) \right]
\end{aligned}$$

Se conocía que  $\sigma^2=1$ , por lo cual:

$$\begin{aligned}
&= \frac{1}{(\sqrt{2\pi})^n} \times \exp \left[ -\frac{1}{2} \left( \sum_{i=1}^n y_i^2 - 2n\bar{y}\mu + n\mu^2 \right) \right] \\
&= \frac{1}{(\sqrt{2\pi})^n} \times \exp \left[ -\frac{1}{2} \sum_{i=1}^n y_i^2 + \frac{1}{2} 2n\bar{y}\mu - \frac{1}{2} n\mu^2 \right] \\
&= \left\{ \frac{1}{(\sqrt{2\pi})^n} \times \exp \left[ -\frac{1}{2} \sum_{i=1}^n y_i^2 \right] \right\} \times \exp \left[ n\bar{y}\mu - \frac{1}{2} n\mu^2 \right] \\
&= h(y) \times g(\bar{y}, \mu)
\end{aligned}$$

Por lo tanto,  $\bar{y}$  es un estimador suficiente para  $\mu$ . □

2. b) ¿Cuál es la distribución de  $\bar{Y}$  con sus parámetros? (Incluya la justificación).

*Solución.* Considérese el teorema 4.7:

**Teorema 7.1**

Let  $Y_1, Y_2, \dots, Y_n$  be a random sample of size  $n$  from a normal distribution with mean  $\mu$  and variance  $\sigma$ . Then

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

is normally distributed with mean  $\mu_{\bar{Y}} = \mu$  and variance  $\sigma_{\bar{Y}}^2 = \sigma^2/n$ .

Entonces, podemos concluir que  $\bar{Y}$  tiene una distribución normal con media  $\mu_{\bar{Y}} = \mu$  y varianza  $\sigma_{\bar{Y}}^2 = 1/n$ . □

3. c) Encuentre la función generadora de momentos de  $\bar{Y}$  (Incluya la justificación).

*Solución.* Vamos a tomar como referencia el cuadro 2 del apéndice 2:

Table 2 Continuous Distributions

| Distribution | Probability Function  | Mean                            | Variance                             | Moment-Generating Function                                     |
|--------------|---|---------------------------------|--------------------------------------|--|
| Uniform      | $f(y) = \frac{1}{\theta_2 - \theta_1}; \theta_1 \leq y \leq \theta_2$   | $\frac{\theta_1 + \theta_2}{2}$ | $\frac{(\theta_2 - \theta_1)^2}{12}$ | $\frac{e^{t\theta_2} - e^{t\theta_1}}{t(\theta_2 - \theta_1)}$ |
| Normal       | $f(y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\left(\frac{1}{2\sigma^2}\right)(y - \mu)^2\right]$<br>$-\infty < y < +\infty$ | $\mu$                           | $\sigma^2$                           | $\exp\left(\mu t + \frac{t^2\sigma^2}{2}\right)$               |

La demostración del caso general es la siguiente:

$$\begin{aligned}
 m_U(t) &= E(\exp(tU)) \\
 &= \int_{-\infty}^{\infty} \exp(tU) \cdot f(U) dU \\
 &= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(tU - \frac{(U - \mu)^2}{2\sigma^2}\right) dU \\
 &= \frac{\sqrt{2}\sigma}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left((\sqrt{2}\sigma z + \mu)t - z^2\right) dz \quad \text{sustituyendo } z = \frac{U - \mu}{\sqrt{2}\sigma} \\
 &= \frac{\exp\{\mu t\}}{\sqrt{\pi}} \int_{-\infty}^{\infty} \exp\left(-\left(z^2 - \sqrt{2}\sigma z t\right)\right) dz \\
 &= \frac{\exp\{\mu t\}}{\sqrt{\pi}} \int_{-\infty}^{\infty} \exp\left(-\left(z - \frac{\sqrt{2}}{2}\sigma t\right)^2 + \frac{1}{2}\sigma^2 t^2\right) dz \\
 &= \frac{\exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right)}{\sqrt{\pi}} \int_{-\infty}^{\infty} \exp(-v^2) dv \quad \text{sustituyendo } v = z - \frac{\sqrt{2}}{2}\sigma t \\
 &= \frac{\sqrt{\pi} \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right)}{\sqrt{\pi}} \\
 &= \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right)
 \end{aligned}$$

Para el caso en donde  $\sigma^2 = 1$

$$= \exp\left(\mu t + \frac{1}{2}t^2\right)$$

□

4. d) Calcule  $E(\bar{Y}^2)$  y  $E(\bar{Y}^4)$ , utilizando la función generadora de momentos del inciso de  $\bar{Y}$ .

*Solución.* Según la literatura:

Valor esperado

$$E(Y^n) = M_Y^{(n)}(0) = \frac{d^n M_Y(0)}{dt^n}$$

Entonces:

WolframAlpha

$d^2/dt^2 e^{(ut+t^2/2)}, t=0$

Input interpretation

$\frac{\partial^2 e^{ut+t^2/2}}{\partial t^2}$  where  $t = 0$

Result

$u^2 + 1$

$$E(Y^2) = M_Y^{(2)}(0) = \frac{d^2 M_Y(0)}{dt^2} = \mu^2 + 1$$

Entonces, tenemos  $E(Y_i^2) = \mu^2 + 1$  por la deducción del teorema 5.12, podemos asumir que:

$$E(\bar{Y}^2) = \mu^2 + \frac{1}{n}.$$

Por otra parte,

WolframAlpha

$d^4/dt^4 e^{(ut+t^2/2)}, t=0$

Input interpretation

$\frac{\partial^4 e^{ut+t^2/2}}{\partial t^4}$  where  $t = 0$

Result

$u^4 + 6u^2 + 3$

$$E(Y^4) = M_Y^{(4)}(0) = \frac{d^4 M_Y(0)}{dt^4} = \mu^4 + 6\mu^2 + 3$$

Entonces, tenemos  $E(Y_i^4) = \mu^4 + 6\mu^2 + 3$  por la deducción del teorema 5.12, podemos asumir que:

$$E(\bar{Y}^4) = \mu^4 + \frac{6\mu^2}{n} + \frac{3}{n^2}.$$

□

5. e) Demuestre que el MUEV (estimador insesgado de varianza mínima) de  $\mu^2$  es  $\hat{\mu}^2 = \bar{Y}^2 - \frac{1}{n}$ .

*Solución.* Sabemos que  $\bar{Y}$  es suficiente para  $\mu$ . Además, sabemos que  $\sigma=1$ , por lo que  $\bar{Y}$  tiene una distribución normal con media  $\mu$  y varianza  $1/n$ . Entonces,

$$E(\bar{Y}^2) = \mu^2 + \frac{1}{n} \implies E\left(\bar{Y}^2 - \frac{1}{n}\right) = \mu^2$$

Entonces, tenemos un estimador insesgado de  $\mu^2$ . Ahora, tomando en cuenta el siguiente teorema:

#### The Rao–Blackwell Theorem

Let  $\hat{\theta}$  be an unbiased estimator for  $\theta$  such that  $VAR(\hat{\theta}) < \infty$ . If  $U$  is a sufficient statistic for  $\theta$ , define  $\hat{\theta}^* = E(\hat{\theta}|U)$ . Then, for all  $\theta$ ,

$$E(\hat{\theta}^*) = \theta \quad \text{y} \quad VAR(\hat{\theta}^*) \leq VAR(\hat{\theta}).$$

Implica que  $\hat{\mu}^2 = \bar{Y}^2 - \frac{1}{n}$  es un MVUE de  $\mu^2$ . □

6. f) Obtenga la  $VAR(\hat{\mu}^2)$ , utilizando el resultado en d ).

*Solución.*

$$\begin{aligned} VAR(\hat{\mu}^2) &= VAR\left(\bar{Y}^2 - \frac{1}{n}\right) = VAR\left(\bar{Y}^2\right) = E(\bar{Y}^4) - [E(\bar{Y}^2)]^2 = \\ &= \mu^4 + \frac{6\mu^2}{n} + \frac{3}{n^2} - \left[\mu^2 + \frac{1}{n}\right]^2 = \frac{(2 + 4n\mu^2)}{n^2}. \end{aligned}$$

□

(Valor 25 puntos).

## 2. Problema 2

Los estimadores de máxima verosimilitud tienen propiedades interesantes cuando se trabaja con muestras grandes. Suponga que  $t(\theta)$  es una función derivable en  $\theta$ . Por la propiedad de invarianza, se tiene que si  $\hat{\theta}$  es el MLE de  $\theta$ , entonces el MLE de  $t(\theta)$  está dada por  $t(\hat{\theta})$ . En algunas condiciones de regularidad que se cumplen para las distribuciones que se consideren,  $t(\hat{\theta})$  es un estimador consistente para  $t(\theta)$ . Además, para tamaño de muestras grandes,

$$Z = \frac{t(\hat{\theta}) - t(\theta)}{\sqrt{\left[\frac{\partial t(\theta)}{\partial \theta}\right]^2 / n E\left[-\frac{\partial^2 \ln[f(Y|\theta)]}{\partial \theta^2}\right]}}$$

tiene aproximadamente una distribución normal estándar, donde  $f(Y|\theta)$  es la función densidad correspondiente a la distribución continua de interés, evaluada en el valor aleatorio  $Y$ . En el caso discreto, el resultado análogo se cumple con la función de probabilidad evaluada en el valor aleatorio  $Y$ ,  $p(Y|\theta)$ , se sustituye por la densidad  $f(Y|\theta)$ .

## Nota 1

Under the following conditions

**Table 8.1 Expected values and standard errors of some common point estimators**

| Target<br>Parameter<br>$\theta$ | Sample<br>Size(s) | Point<br>Estimator<br>$\hat{\theta}$ | $E(\hat{\theta})$ | Standard<br>Error<br>$\sigma_{\hat{\theta}}$                        |
|---------------------------------|-------------------|--------------------------------------|-------------------|---|
| $\mu$                           | $n$               | $\bar{Y}$                            | $\mu$             | $\frac{\sigma}{\sqrt{n}}$   |
| $p$                             | $n$               | $\hat{p} = \frac{Y}{n}$              | $p$               | $\sqrt{\frac{pq}{n}}$   |
| $\mu_1 - \mu_2$                 | $n_1$ and $n_2$   | $\bar{Y}_1 - \bar{Y}_2$              | $\mu_1 - \mu_2$   | $\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}^{*\dagger}$ |
| $p_1 - p_2$                     | $n_1$ and $n_2$   | $\hat{p}_1 - \hat{p}_2$              | $p_1 - p_2$       | $\sqrt{\frac{p_1q_1}{n_1} + \frac{p_2q_2}{n_2}}^{\dagger}$          |

\* $\sigma_1^2$  and  $\sigma_2^2$  are the variances of populations 1 and 2, respectively.

$\dagger$ The two samples are assumed to be independent.

If the target parameter  $\theta$  is  $\mu, p, \mu_1 - \mu_2$ , or  $p_1 - p_2$ , then for large samples,

$$Z = \frac{\hat{\theta} - \theta}{\sigma_{\hat{\theta}}}$$

possesses approximately a standard normal distribution. Consequently,  $Z = \frac{\hat{\theta} - \theta}{\sigma_{\hat{\theta}}}$  forms (at least approximately) a pivotal quantity, and the pivotal method can be employed to develop confidence intervals for the target parameter  $\theta$ .

For interval confidence the key formula is:

$$\hat{\theta} \pm z_{\alpha/2} \sigma_{\hat{\theta}}.$$

When  $\theta = \mu$  is the target parameter, then  $\hat{\theta} = \bar{Y}$  and  $\sigma_{\hat{\theta}}^2 = \sigma^2/n$ .

## Nota 2

Por las condiciones de la nota 1, entonces, el intervalo buscado para  $Z$  es:

$$t(\hat{\theta}) \pm z_{\alpha/2} \sqrt{\left[ \frac{\partial t(\theta)}{\partial \theta} \right]^2 / n E \left[ -\frac{\partial^2 \ln[f(Y | \theta)]}{\partial \theta^2} \right]} \approx$$

$$\approx t(\hat{\theta}) \pm z_{\alpha/2} \sqrt{\left[ \frac{\partial t(\hat{\theta})}{\partial \hat{\theta}} \right]^2 / n E \left[ -\frac{\partial^2 \ln[f(Y | \hat{\theta})]}{\partial \hat{\theta}^2} \right]}$$

En el caso particular, para una variable aleatoria con distribución de Bernoulli,  $p(y | p) = p^y(1-p)^{1-y}$ , donde  $y = 0, 1$ . Si  $Y_1, \dots, Y_n$  es una muestra aleatoria de tamaño  $n$  de dicha distribución.

1. a) Encuentre el MLE para el parámetro  $p$ .

*Solución.* Comenzamos definiendo el MLE, como:

#### Method of Maximum Likelihood

Suppose that the likelihood function depends on  $k$  parameters  $\theta_1, \theta_2, \dots, \theta_k$ . Choose as estimates those values of the parameters that maximize the likelihood  $L(y_1, y_2, \dots, y_n | \theta_1, \theta_2, \dots, \theta_k)$ .

$\Rightarrow$  Usando la definición de verosimilitud:

$$\begin{aligned}
 p(y|p) &= L(y_1, y_2, \dots, y_n | p) = p^y (1-p)^{1-y}, \quad \left( y = \frac{1}{n} \sum_{i=1}^n y_i \right) \\
 \ln [p(y|p)] &= \ln [p^y (1-p)^{1-y}] = \ln [p^y] + \ln [(1-p)^{1-y}] \\
 &= y \ln [p] + (1-y) \ln [(1-p)] \\
 \frac{\partial \ln [p(y|p)]}{\partial p} &= \frac{y}{p} + \frac{(1-y)}{(1-p)} (-1) = \frac{y}{p} - \frac{(1-y)}{(1-p)} \quad (*) \\
 \frac{\partial^2 \ln [p(y|p)]}{\partial p^2} &= -\frac{y}{p^2} - \frac{(1-y)}{(1-p)^2} \quad (**) \text{ Nos ayudará en el inciso 3. c) }
 \end{aligned}$$

Igualando (\*) a 0:

$$\frac{y}{\hat{p}} - \frac{(1-y)}{(1-\hat{p})} = 0 \Rightarrow \hat{p} = y.$$

□

2. b) Encuentre el MLE para la expresión  $p(1-p)$ .

*Solución.* Bajo los supuestos usuales, el MLE de  $t(p) = p(1-p)$  es  $t(\hat{p}) = \hat{p}(1-\hat{p})$ . En donde:

$$\begin{aligned}
 t(p) &= p(1-p) = p - p^2 \\
 \frac{dt(p)}{dp} &= 1 - 2p
 \end{aligned}$$

Igualando a 0:

$$1 - 2\hat{p} = 0 \Rightarrow \hat{p} = \frac{1}{2}.$$

□

3. c) Construya un intervalo de confianza de  $100(1-\alpha)\%$  para  $p(1-p)$ , la varianza de dicha distribución (suponga una muestra grande).

*Solución.* Ahora, tómese como referencia la **Nota 2**. Aún nos falta calcular:

$$E \left[ -\frac{\partial^2 \ln[f(Y | \hat{\theta})]}{\partial \hat{\theta}^2} \right] = E \left[ -\frac{\partial^2 \ln[p(y | \hat{p})]}{\partial \hat{p}^2} \right] = E \left[ -\underbrace{\left( -\frac{y}{p^2} - \frac{(1-y)}{(1-p)^2} \right)}_{(**) \text{ del inciso 1 a)} } \right] =$$

Sabemos que  $\hat{p} = y$ , entonces:

$$= \left( \frac{p}{p^2} + \frac{(1-p)}{(1-p)^2} \right) = \frac{1}{p(1-p)}.$$

Entonces, el intervalo de confianza para  $p(1-p)$ , como se estableció en la **Nota 2**, se define:

$$\begin{aligned} t(\hat{p}) \pm z_{\alpha/2} \sqrt{\left[ \frac{\partial t(\hat{p})}{\partial \hat{p}} \right]^2 / n E \left[ -\frac{\partial^2 \ln[f(Y | \hat{p})]}{\partial \hat{p}^2} \right]} &= \\ = \hat{p}(1-\hat{p}) \pm z_{\alpha/2} \sqrt{[1-2\hat{p}]^2 / n \left( \frac{1}{\hat{p}(1-\hat{p})} \right)} &= \\ = \hat{p}(1-\hat{p}) \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})(1-2\hat{p})^2}{n}}. \end{aligned}$$

□

(Valor 25 puntos).

### 3. Problema 3

Suponga que  $Y_1, Y_2, \dots, Y_n$  es una muestra aleatoria de la distribución de Poisson con media  $\lambda > 0$ .

1. a) Encuentre el estimador del método de momentos para  $\lambda$ .

*Solución.* Comenzamos definiendo el estimador del método de momentos como:

#### Method of moments

Choose as estimates those values of the parameters that are solutions of the equations  $\mu'_k = m'_k$ , for  $k = 1, 2, \dots, t$ , where  $t$  is the number of parameters to be estimated.

$$\mu'_k = E(Y^k) \quad \text{and} \quad m'_k = \frac{1}{n} \sum_{i=1}^n Y_i^k.$$

Sabemos por hipótesis que  $\mu = \lambda$ .  $\implies$  El estimador del método de momentos está definido como:

$$\hat{\lambda} = m'_1 = \frac{1}{n} \sum_{i=1}^n Y_i^1 = \bar{Y}.$$

□

2. b) Encuentre el estimador de máxima verosimilitud (MLE)  $\hat{\lambda}$  para  $\lambda$ .

*Solución.* Comenzamos definiendo el MLE, como:



**Method of Maximum Likelihood**

Suppose that the likelihood function depends on  $k$  parameters  $\theta_1, \theta_2, \dots, \theta_k$ . Choose as estimates those values of the parameters that maximize the likelihood  $L(y_1, y_2, \dots, y_n | \theta_1, \theta_2, \dots, \theta_k)$ .

**Función de probabilidad de Poisson**

Apéndice 2 - Distribuciones discretas, se define como:

$$p(y) = \frac{\lambda^y e^{-\lambda}}{y!}, \quad y = 1, 2, 3, \dots$$

$\Rightarrow$  Usando la definición de verosimilitud:

$$\begin{aligned} L(\lambda) &= p(y_1, y_2, \dots, y_n | \lambda) \\ &= p(y_1 | \lambda) \times p(y_2 | \lambda) \times \dots \times p(y_n | \lambda) \\ &= \left\{ \frac{\lambda^{y_1} e^{-\lambda}}{y_1!} \right\} \times \left\{ \frac{\lambda^{y_2} e^{-\lambda}}{y_2!} \right\} \times \dots \times \left\{ \frac{\lambda^{y_n} e^{-\lambda}}{y_n!} \right\} \\ &= \prod_{i=1}^n \frac{\lambda^{y_i} e^{-\lambda}}{y_i!} = \frac{(\prod_{i=1}^n \lambda^{y_i}) (\prod_{i=1}^n e^{-\lambda})}{\prod_{i=1}^n y_i!} = \frac{(\lambda^{\sum_{i=1}^n y_i}) (n e^{-\lambda})}{\prod_{i=1}^n y_i!} \\ \ln [L(\lambda)] &= \ln \left[ \frac{(\lambda^{\sum_{i=1}^n y_i}) (n e^{-\lambda})}{\prod_{i=1}^n y_i!} \right] = \ln \left[ (\lambda^{\sum_{i=1}^n y_i}) (n e^{-\lambda}) \right] - \ln \left[ \prod_{i=1}^n y_i! \right] \\ &= \ln \left[ (\lambda^{\sum_{i=1}^n y_i}) \right] + \ln [n e^{-\lambda}] - \ln \left[ \prod_{i=1}^n y_i! \right] \\ &= \left[ \sum_{i=1}^n y_i \right] [\ln(\lambda)] - \lambda n - \ln \left[ \prod_{i=1}^n y_i! \right] \\ \frac{d \ln [L(\lambda)]}{d\lambda} &= \frac{1}{\lambda} \left[ \sum_{i=1}^n y_i \right] - n - 0 \end{aligned}$$

Igualamos a 0 la expresión:

$$\frac{1}{\hat{\lambda}} \left[ \sum_{i=1}^n y_i \right] - n = 0 \Rightarrow \hat{\lambda} = \frac{1}{n} \left[ \sum_{i=1}^n y_i \right] = \bar{Y}$$

□

(Valor 25 puntos).

## 4. Problema 4

Sea  $Y$  una variable aleatoria que representa el número de éxitos en  $n$  intentos independientes con probabilidad  $p$  de éxito en cada intento. Además,

$$Y = \sum_{i=1}^n Y_i$$

donde

$$Y_i = \begin{cases} 1, & \text{si el } i\text{-ésimo intento resulta en éxito} \\ 0, & \text{en el otro caso} \end{cases}$$

para  $i = 1, \dots, n$

1. a) Demuestre que  $\hat{p}_n = \frac{Y}{n}$  es un estimador insesgado de  $p$ .

*Solución.* Tenemos las siguientes definiciones::

### Definición 8.2 - Sesgo

Let  $\hat{\theta}$  be a point estimator for a parameter  $\theta$ . Then  $\hat{\theta}$  is an unbiased estimator if  $E(\hat{\theta}) = \theta$ . If  $E(\hat{\theta}) \neq \theta$ ,  $\hat{\theta}$  is said to be biased.

### Definición 8.3 - Sesgo

The bias of a point estimator  $\hat{\theta}$  is given by  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$ .

A probar:  $E(\hat{p}_n) = p$ . Entonces:

$$\begin{aligned} E(\hat{p}_n) &= E\left(\frac{Y}{n}\right) = \underbrace{\frac{1}{n}E(Y)}_{\text{Teorema 5.7}} = \frac{1}{n}E\left(\sum_{i=1}^n Y_i\right) = \frac{1}{n}E(Y_1 + Y_2 + \dots + Y_n) = \\ &= \frac{1}{n} \left[ \underbrace{E(Y_1) + E(Y_2) + \dots + E(Y_n)}_{E(Y_i)=p, \text{ definición de valor esperado.}} \right] = \frac{1}{n} [p + p + \dots + p] = \frac{1}{n}(np) = p \end{aligned}$$

□

2. b) Demuestre que  $\hat{p}_n$  es un estimador consistente de  $p$ .

*Solución.* Procedemos a calcular la varianza del estimador, es decir:

$$VAR(\hat{p}_n) = \frac{pq}{n}, \quad q = (1 - p). \quad (\text{Deducción en el ejercicio 5.28}).$$

$\Rightarrow$  Tomamos como referencia el teorema 9.1:

**Teorema 9.1**

An unbiased estimator  $\hat{\theta}_n$  for  $\theta$  is a consistent estimator of  $\theta$  if

$$\lim_{n \rightarrow \infty} \text{VAR}(\hat{\theta}_n) = 0.$$

$$\implies \lim_{n \rightarrow \infty} \text{VAR}(\hat{p}_n) = \lim_{n \rightarrow \infty} \text{VAR}\left(\frac{pq}{n}\right) = \text{VAR}(0) = 0.$$

□

3. c) Cuando  $n$  es grande, demuestre que la distribución de  $\frac{\hat{p}_n - p}{\sqrt{p(1-p)/n}}$  converge a una distribución normal estándar.

*Solución.* Considerando el teorema del límite central:

**Teorema 7.4**

Let  $Y_1, Y_2, \dots, Y_n$  be independent and identically distributed random variables with  $E(Y_i) = \mu$  and  $V(Y_i) = \sigma^2 < \infty$ . Define

$$U_n = \frac{\sum_{i=1}^n Y_i - n\mu}{\sigma\sqrt{n}} = \frac{\bar{Y} - \mu}{\sigma/\sqrt{n}}.$$

Then, the distribution function  $U_n$  converges to the standard normal distribution function as  $n \rightarrow \infty$ .

Dados los 2 incisos anteriores tenemos  $E(Y_i) = p$  y  $\text{VAR}(Y_i) = p(1-p)$ . Por hipótesis, sabemos  $Y = \sum_{i=1}^n Y_i$ . Definimos:

$$U_n = \frac{Y - np}{\sqrt{p(1-p)}\sqrt{n}} = \frac{\frac{Y - np}{n}}{\frac{\sqrt{p(1-p)}}{n}} = \frac{\hat{p}_n - p}{\sqrt{\frac{p(1-p)}{n}}}$$

Por lo tanto, la distribución converge a una distribución normal. □

4. d) Cuando  $n$  es grande, demuestre que la distribución de  $\frac{\hat{p}_n - p}{\sqrt{\hat{p}_n(1-\hat{p}_n)/n}}$  converge a una distribución normal estándar.

*Solución.* Sabemos que  $\hat{p}_n$  es consistente, por lo que  $(1 - \hat{p}_n)$  también debe ser consistente; por el inciso b del teorema 9.2, entonces  $\hat{p}_n(1 - \hat{p}_n)$  es consistente para  $p(1 - p)$ .

$$\implies \frac{U_n}{W_n} = \frac{\hat{p}_n - p}{\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}} = \frac{\frac{\hat{p}_n - p}{\sqrt{\frac{p(1-p)}{n}}}}{\frac{\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}}{\sqrt{\frac{p(1-p)}{n}}}} = \frac{\underbrace{\frac{\hat{p}_n - p}{\sqrt{\frac{p(1-p)}{n}}}}_{\text{Inciso anterior.}}}{\underbrace{\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{p(1-p)}}}_{\text{Su probabilidad converge a 1.}}}$$

Por lo tanto,  $U_n$  converge a una distribución normal y la probabilidad de  $W_n$  converge a 1. Considerando:

**Teorema 9.3**

Suppose that  $U_n$  has a distribution function that converges to a standard normal distribution function as  $n \rightarrow \infty$ . If  $W_n$  converges in probability to 1, then the distribution function of  $U_n/W_n$  converges to a standard normal distribution function.

Se concluye que la distribución  $U_n/W_n$  converge a una distribución normal estándar.  $\square$

(Valor 25 puntos)

## Referencias

Wackerly, D., Mendenhall, W., and Scheaffer, R. L. (2014). *Mathematical statistics with applications*. Cengage Learning.