

Universidad del Valle de Guatemala
Departamento de Matemática
Licenciatura en Matemática Aplicada

Estudiante: Rudik Roberto Rompich
E-mail: rom19857@uvg.edu.gt
Carné: 19857

MM2036 - Estadística Matemática - Catedrático: Paulo Mejía
23 de mayo de 2021

Parcial 4

Instrucciones: Resuelva los siguientes problema. Favor hacer la solución en latex y cargar el archivo latex y pdf en la tarea de Canvas. Para la resolución de los problemas, se utilizará el libro de Wackerly et al. (2014).

1. Problema 1

Sea Y_1, Y_2, \dots, Y_n una muestra aleatoria de una distribución normal con media μ y varianza 1.

Definición 4.8 - Distribución Normal

A random variable Y is said to have a normal probability distribution if and only if, for $\sigma > 0$ and $-\infty < \mu < \infty$, the density function of Y is

$$f(y) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(y-\mu)^2/(2\sigma^2)}, \quad -\infty < y < \infty$$

1. a) Demuestre que \bar{Y} es un estimador suficiente para μ .

Solución. Comenzamos definiendo al estimador suficiente como:

Teorema 9.4 - Estimador suficiente

Let U be a statistic based on the random sample Y_1, Y_2, \dots, Y_n . Then U is a sufficient statistic for the estimation of a parameter θ if and only if the likelihood $L(\theta) = L(y_1, y_2, \dots, y_n|\theta)$ can be factored into two nonnegative functions,

$$L(y_1, y_2, \dots, y_n|\theta) = g(u, \theta) \times h(y_1, y_2, \dots, y_n)$$

where $g(u, \theta)$ is a function only of u and θ and $h(y_1, y_2, \dots, y_n)$ is not a function of θ .

$$\begin{aligned}
L(y_1, y_2, \dots, y_n | \mu) &= L(y_1 | \mu) \times L(y_2 | \mu) \times \dots \times L(y_n | \mu) \\
&= \frac{1}{\sigma \sqrt{2\pi}} \exp \left[\frac{-(y_1 - \mu)^2}{(2\sigma^2)} \right] \times \frac{1}{\sigma \sqrt{2\pi}} \exp \left[\frac{-(y_2 - \mu)^2}{(2\sigma^2)} \right] \times \dots \times \\
&\times \dots \times \frac{1}{\sigma \sqrt{2\pi}} \exp \left[\frac{-(y_n - \mu)^2}{(2\sigma^2)} \right] \\
&= \frac{1}{\sigma^n (\sqrt{2\pi})^n} \times \exp \left[-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n (y_i - \mu)^2 \right) \right] \\
&= \frac{1}{\sigma^n (\sqrt{2\pi})^n} \times \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i^2 - 2y_i\mu + \mu^2) \right] \\
&= \frac{1}{\sigma^n (\sqrt{2\pi})^n} \times \exp \left[-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n y_i^2 - 2 \sum_{i=1}^n y_i\mu + \sum_{i=1}^n \mu^2 \right) \right] \\
&= \frac{1}{\sigma^n (\sqrt{2\pi})^n} \times \exp \left[-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n y_i^2 - 2n\bar{y}\mu + n\mu^2 \right) \right]
\end{aligned}$$

Se conocía que $\sigma^2=1$, por lo cual:

$$\begin{aligned}
&= \frac{1}{(\sqrt{2\pi})^n} \times \exp \left[-\frac{1}{2} \left(\sum_{i=1}^n y_i^2 - 2n\bar{y}\mu + n\mu^2 \right) \right] \\
&= \frac{1}{(\sqrt{2\pi})^n} \times \exp \left[-\frac{1}{2} \sum_{i=1}^n y_i^2 + \frac{1}{2} 2n\bar{y}\mu - \frac{1}{2} n\mu^2 \right] \\
&= \left\{ \frac{1}{(\sqrt{2\pi})^n} \times \exp \left[-\frac{1}{2} \sum_{i=1}^n y_i^2 \right] \right\} \times \exp \left[n\bar{y}\mu - \frac{1}{2} n\mu^2 \right] \\
&= h(y) \times g(\bar{y}, \mu)
\end{aligned}$$

Por lo tanto, \bar{y} es un estimador suficiente para μ . □

2. b) ¿Cuál es la distribución de \bar{Y} con sus parámetros? (Incluya la justificación).

Solución. Considérese el teorema 4.7:

Teorema 7.1

Let Y_1, Y_2, \dots, Y_n be a random sample of size n from a normal distribution with mean μ and variance σ . Then

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

is normally distributed with mean $\mu_{\bar{Y}} = \mu$ and variance $\sigma_{\bar{Y}}^2 = \sigma^2/n$.

Entonces, podemos concluir que \bar{Y} tiene una distribución normal con media $\mu_{\bar{Y}} = \mu$ y varianza $\sigma_{\bar{Y}}^2 = 1/n$. □

3. c) Encuentre la función generadora de momentos de \bar{Y} (Incluya la justificación).

Solución. Vamos a tomar como referencia el cuadro 2 del apéndice 2:

Table 2 Continuous Distributions

Distribution	Probability Function	Mean	Variance	Moment-Generating Function
Uniform	$f(y) = \frac{1}{\theta_2 - \theta_1}; \theta_1 \leq y \leq \theta_2$	$\frac{\theta_1 + \theta_2}{2}$	$\frac{(\theta_2 - \theta_1)^2}{12}$	$\frac{e^{t\theta_2} - e^{t\theta_1}}{t(\theta_2 - \theta_1)}$
Normal	$f(y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\left(\frac{1}{2\sigma^2}\right)(y - \mu)^2\right]$ $-\infty < y < +\infty$	μ	σ^2	$\exp\left(\mu t + \frac{t^2\sigma^2}{2}\right)$

La demostración del caso general es la siguiente:

$$\begin{aligned}
 m_U(t) &= E(\exp(tU)) \\
 &= \int_{-\infty}^{\infty} \exp(tU) \cdot f(U) dU \\
 &= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(tU - \frac{(U - \mu)^2}{2\sigma^2}\right) dU \\
 &= \frac{\sqrt{2}\sigma}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left((\sqrt{2}\sigma z + \mu)t - z^2\right) dz \quad \text{sustituyendo } z = \frac{U - \mu}{\sqrt{2}\sigma} \\
 &= \frac{\exp\{\mu t\}}{\sqrt{\pi}} \int_{-\infty}^{\infty} \exp\left(-\left(z^2 - \sqrt{2}\sigma z t\right)\right) dz \\
 &= \frac{\exp\{\mu t\}}{\sqrt{\pi}} \int_{-\infty}^{\infty} \exp\left(-\left(z - \frac{\sqrt{2}}{2}\sigma t\right)^2 + \frac{1}{2}\sigma^2 t^2\right) dz \\
 &= \frac{\exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right)}{\sqrt{\pi}} \int_{-\infty}^{\infty} \exp(-v^2) dv \quad \text{sustituyendo } v = z - \frac{\sqrt{2}}{2}\sigma t \\
 &= \frac{\sqrt{\pi} \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right)}{\sqrt{\pi}} \\
 &= \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right)
 \end{aligned}$$

Para el caso en donde $\sigma^2 = 1$

$$= \exp\left(\mu t + \frac{1}{2}t^2\right)$$

□

4. d) Calcule $E(\bar{Y}^2)$ y $E(\bar{Y}^4)$, utilizando la función generadora de momentos del inciso de \bar{Y} .

Solución. Según la literatura:

Valor esperado

$$E(Y^n) = M_Y^{(n)}(0) = \frac{d^n M_Y(0)}{dt^n}$$

Entonces:

WolframAlpha

$d^2/dt^2 e^{(ut+t^2/2)}, t=0$

Input interpretation

$\frac{\partial^2 e^{ut+t^2/2}}{\partial t^2}$ where $t = 0$

Result

$u^2 + 1$

$$E(Y^2) = M_Y^{(2)}(0) = \frac{d^2 M_Y(0)}{dt^2} = \mu^2 + 1$$

Entonces, tenemos $E(Y_i^2) = \mu^2 + 1$ por la deducción del teorema 5.12, podemos asumir que:

$$E(\bar{Y}^2) = \mu^2 + \frac{1}{n}.$$

Por otra parte,

WolframAlpha

$d^4/dt^4 e^{(ut+t^2/2)}, t=0$

Input interpretation

$\frac{\partial^4 e^{ut+t^2/2}}{\partial t^4}$ where $t = 0$

Result

$u^4 + 6u^2 + 3$

$$E(Y^4) = M_Y^{(4)}(0) = \frac{d^4 M_Y(0)}{dt^4} = \mu^4 + 6\mu^2 + 3$$

Entonces, tenemos $E(Y_i^4) = \mu^4 + 6\mu^2 + 3$ por la deducción del teorema 5.12, podemos asumir que:

$$E(\bar{Y}^4) = \mu^4 + \frac{6\mu^2}{n} + \frac{3}{n^2}.$$

□

5. e) Demuestre que el MUEV (estimador insesgado de varianza mínima) de μ^2 es $\hat{\mu}^2 = \bar{Y}^2 - \frac{1}{n}$.

Solución. Sabemos que \bar{Y} es suficiente para μ . Además, sabemos que $\sigma=1$, por lo que \bar{Y} tiene una distribución normal con media μ y varianza $1/n$. Entonces,

$$E(\bar{Y}^2) = \mu^2 + \frac{1}{n} \implies E\left(\bar{Y}^2 - \frac{1}{n}\right) = \mu^2$$

Entonces, tenemos un estimador insesgado de μ^2 . Ahora, tomando en cuenta el siguiente teorema:

The Rao–Blackwell Theorem

Let $\hat{\theta}$ be an unbiased estimator for θ such that $VAR(\hat{\theta}) < \infty$. If U is a sufficient statistic for θ , define $\hat{\theta}^* = E(\hat{\theta}|U)$. Then, for all θ ,

$$E(\hat{\theta}^*) = \theta \quad \text{y} \quad VAR(\hat{\theta}^*) \leq VAR(\hat{\theta}).$$

Implica que $\hat{\mu}^2 = \bar{Y}^2 - \frac{1}{n}$ es un MVUE de μ^2 . □

6. f) Obtenga la $VAR(\hat{\mu}^2)$, utilizando el resultado en d).

Solución.

$$\begin{aligned} VAR(\hat{\mu}^2) &= VAR\left(\bar{Y}^2 - \frac{1}{n}\right) = VAR\left(\bar{Y}^2\right) = E(\bar{Y}^4) - [E(\bar{Y}^2)]^2 = \\ &= \mu^4 + \frac{6\mu^2}{n} + \frac{3}{n^2} - \left[\mu^2 + \frac{1}{n}\right]^2 = \frac{(2 + 4n\mu^2)}{n^2} \end{aligned}$$

□

(Valor 25 puntos).

2. Problema 2

Los estimadores de máxima verosimilitud tienen propiedades interesantes cuando se trabaja con muestras grandes. Suponga que $t(\theta)$ es una función derivable en θ . Por la propiedad de invarianza, se tiene que si $\hat{\theta}$ es el MLE de θ , entonces el MLE de $t(\theta)$ está dada por $t(\hat{\theta})$. En algunas condiciones de regularidad que se cumplen para las distribuciones que se consideren, $t(\hat{\theta})$ es un estimador consistente para $t(\theta)$. Además, para tamaño de muestras grandes,

$$Z = \frac{t(\hat{\theta}) - t(\theta)}{\sqrt{\left[\frac{\partial t(\theta)}{\partial \theta}\right]^2 / n E\left[-\frac{\partial^2 \ln[f(Y|\theta)]}{\partial \theta^2}\right]}}$$

tiene aproximadamente una distribución normal estándar, donde $f(Y | \theta)$ es la función densidad correspondiente a la distribución continua de interés, evaluada en el valor aleatorio Y . En el caso discreto, el resultado análogo se cumple con la función de probabilidad evaluada en el valor aleatorio Y , $p(Y | \theta)$, se sustituye por la densidad $f(Y | \theta)$.

Nota 1

Under the following conditions

Table 8.1 Expected values and standard errors of some common point estimators

Target Parameter θ	Sample Size(s)	Point Estimator $\hat{\theta}$	$E(\hat{\theta})$	Standard Error $\sigma_{\hat{\theta}}$
μ	n	\bar{Y}	μ	$\frac{\sigma}{\sqrt{n}}$
p	n	$\hat{p} = \frac{Y}{n}$	p	$\sqrt{\frac{pq}{n}}$
$\mu_1 - \mu_2$	n_1 and n_2	$\bar{Y}_1 - \bar{Y}_2$	$\mu_1 - \mu_2$	$\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}^{*\dagger}$
$p_1 - p_2$	n_1 and n_2	$\hat{p}_1 - \hat{p}_2$	$p_1 - p_2$	$\sqrt{\frac{p_1q_1}{n_1} + \frac{p_2q_2}{n_2}}^{\dagger}$

* σ_1^2 and σ_2^2 are the variances of populations 1 and 2, respectively.

\dagger The two samples are assumed to be independent.

If the target parameter θ is $\mu, p, \mu_1 - \mu_2$, or $p_1 - p_2$, then for large samples,

$$Z = \frac{\hat{\theta} - \theta}{\sigma_{\hat{\theta}}}$$

possesses approximately a standard normal distribution. Consequently, $Z = \frac{\hat{\theta} - \theta}{\sigma_{\hat{\theta}}}$ forms (at least approximately) a pivotal quantity, and the pivotal method can be employed to develop confidence intervals for the target parameter θ .

For interval confidence the key formula is:

$$\hat{\theta} \pm z_{\alpha/2} \sigma_{\hat{\theta}}.$$

When $\theta = \mu$ is the target parameter, then $\hat{\theta} = \bar{Y}$ and $\sigma_{\hat{\theta}}^2 = \sigma^2/n$.

Nota 2

Por las condiciones de la nota 1, entonces, el intervalo buscado para Z es:

$$t(\hat{\theta}) \pm z_{\alpha/2} \sqrt{\left[\frac{\partial t(\theta)}{\partial \theta} \right]^2 / n E \left[-\frac{\partial^2 \ln[f(Y | \theta)]}{\partial \theta^2} \right]} \approx$$

$$\approx t(\hat{\theta}) \pm z_{\alpha/2} \sqrt{\left[\frac{\partial t(\hat{\theta})}{\partial \hat{\theta}} \right]^2 / n E \left[-\frac{\partial^2 \ln[f(Y | \hat{\theta})]}{\partial \hat{\theta}^2} \right]}$$

En el caso particular, para una variable aleatoria con distribución de Bernoulli, $p(y | p) = p^y(1-p)^{1-y}$, donde $y = 0, 1$. Si Y_1, \dots, Y_n es una muestra aleatoria de tamaño n de dicha distribución.

1. a) Encuentre el MLE para el parámetro p .

Solución. Comenzamos definiendo el MLE, como:

Method of Maximum Likelihood

Suppose that the likelihood function depends on k parameters $\theta_1, \theta_2, \dots, \theta_k$. Choose as estimates those values of the parameters that maximize the likelihood $L(y_1, y_2, \dots, y_n | \theta_1, \theta_2, \dots, \theta_k)$.

\Rightarrow Usando la definición de verosimilitud:

$$p(y|p) = L(y_1, y_2, \dots, y_n | p) = p^y (1-p)^{1-y}, \quad \left(y = \frac{1}{n} \sum_{i=1}^n y_i \right)$$

$$\ln [p(y|p)] = \ln [p^y (1-p)^{1-y}] = \ln [p^y] + \ln [(1-p)^{1-y}]$$

$$= y \ln [p] + (1-y) \ln [(1-p)]$$

$$\frac{\partial \ln [p(y|p)]}{\partial p} = \frac{y}{p} + \frac{(1-y)}{(1-p)} (-1) = \frac{y}{p} - \frac{(1-y)}{(1-p)} \quad (*)$$

$$\frac{\partial^2 \ln [p(y|p)]}{\partial p^2} = -\frac{y}{p^2} - \frac{(1-y)}{(1-p)^2} \quad (**) \text{ Nos ayudará en el inciso 3. c)}$$

Igualando (*) a 0:

$$\frac{y}{\hat{p}} - \frac{(1-y)}{(1-\hat{p})} = 0 \Rightarrow \hat{p} = y.$$

□

2. b) Encuentre el MLE para la expresión $p(1-p)$.

Solución. Bajo los supuestos usuales, el MLE de $t(p) = p(1-p)$ es $t(\hat{p}) = \hat{p}(1-\hat{p})$. En donde:

$$t(p) = p(1-p) = p - p^2$$

$$\frac{dt(p)}{dp} = 1 - 2p$$

Igualando a 0:

$$1 - 2\hat{p} = 0 \Rightarrow \hat{p} = \frac{1}{2}.$$

□

3. c) Construya un intervalo de confianza de $100(1-\alpha)\%$ para $p(1-p)$, la varianza de dicha distribución (suponga una muestra grande).

Solución. Ahora, tómese como referencia la **Nota 2**. Aún nos falta calcular:

$$E \left[-\frac{\partial^2 \ln[f(Y | \hat{\theta})]}{\partial \hat{\theta}^2} \right] = E \left[-\frac{\partial^2 \ln[p(y | \hat{p})]}{\partial \hat{p}^2} \right] = E \left[-\underbrace{\left(-\frac{y}{p^2} - \frac{(1-y)}{(1-p)^2} \right)}_{(**) \text{ del inciso 1 a)} } \right] =$$

Sabemos que $\hat{p} = y$, entonces:

$$= \left(\frac{p}{p^2} + \frac{(1-p)}{(1-p)^2} \right) = \frac{1}{p(1-p)}.$$

Entonces, el intervalo de confianza para $p(1-p)$, como se estableció en la **Nota 2**, se define:

$$\begin{aligned} t(\hat{p}) \pm z_{\alpha/2} \sqrt{\left[\frac{\partial t(\hat{p})}{\partial \hat{p}} \right]^2 / n E \left[-\frac{\partial^2 \ln[f(Y | \hat{p})]}{\partial \hat{p}^2} \right]} &= \\ = \hat{p}(1-\hat{p}) \pm z_{\alpha/2} \sqrt{[1-2\hat{p}]^2 / n \left(\frac{1}{\hat{p}(1-\hat{p})} \right)} &= \\ = \hat{p}(1-\hat{p}) \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})(1-2\hat{p})^2}{n}}. \end{aligned}$$

□

(Valor 25 puntos).

3. Problema 3

Suponga que Y_1, Y_2, \dots, Y_n es una muestra aleatoria de la distribución de Poisson con media $\lambda > 0$.

1. a) Encuentre el estimador del método de momentos para λ .

Solución. Comenzamos definiendo el estimador del método de momentos como:

Method of moments

Choose as estimates those values of the parameters that are solutions of the equations $\mu'_k = m'_k$, for $k = 1, 2, \dots, t$, where t is the number of parameters to be estimated.

$$\mu'_k = E(Y^k) \quad \text{and} \quad m'_k = \frac{1}{n} \sum_{i=1}^n Y_i^k.$$

Sabemos por hipótesis que $\mu = \lambda$. \implies El estimador del método de momentos está definido como:

$$\hat{\lambda} = m'_1 = \frac{1}{n} \sum_{i=1}^n Y_i^1 = \bar{Y}.$$

□

2. b) Encuentre el estimador de máxima verosimilitud (MLE) $\hat{\lambda}$ para λ .

Solución. Comenzamos definiendo el MLE, como:

Method of Maximum Likelihood

Suppose that the likelihood function depends on k parameters $\theta_1, \theta_2, \dots, \theta_k$. Choose as estimates those values of the parameters that maximize the likelihood $L(y_1, y_2, \dots, y_n | \theta_1, \theta_2, \dots, \theta_k)$.

Función de probabilidad de Poisson

Apéndice 2 - Distribuciones discretas, se define como:

$$p(y) = \frac{\lambda^y e^{-\lambda}}{y!}, \quad y = 1, 2, 3, \dots$$

\Rightarrow Usando la definición de verosimilitud:

$$\begin{aligned} L(\lambda) &= p(y_1, y_2, \dots, y_n | \lambda) \\ &= p(y_1 | \lambda) \times p(y_2 | \lambda) \times \dots \times p(y_n | \lambda) \\ &= \left\{ \frac{\lambda^{y_1} e^{-\lambda}}{y_1!} \right\} \times \left\{ \frac{\lambda^{y_2} e^{-\lambda}}{y_2!} \right\} \times \dots \times \left\{ \frac{\lambda^{y_n} e^{-\lambda}}{y_n!} \right\} \\ &= \prod_{i=1}^n \frac{\lambda^{y_i} e^{-\lambda}}{y_i!} = \frac{(\prod_{i=1}^n \lambda^{y_i}) (\prod_{i=1}^n e^{-\lambda})}{\prod_{i=1}^n y_i!} = \frac{(\lambda^{\sum_{i=1}^n y_i}) (n e^{-\lambda})}{\prod_{i=1}^n y_i!} \\ \ln [L(\lambda)] &= \ln \left[\frac{(\lambda^{\sum_{i=1}^n y_i}) (n e^{-\lambda})}{\prod_{i=1}^n y_i!} \right] = \ln \left[(\lambda^{\sum_{i=1}^n y_i}) (n e^{-\lambda}) \right] - \ln \left[\prod_{i=1}^n y_i! \right] \\ &= \ln \left[(\lambda^{\sum_{i=1}^n y_i}) \right] + \ln [n e^{-\lambda}] - \ln \left[\prod_{i=1}^n y_i! \right] \\ &= \left[\sum_{i=1}^n y_i \right] [\ln(\lambda)] - \lambda n - \ln \left[\prod_{i=1}^n y_i! \right] \\ \frac{d \ln [L(\lambda)]}{d\lambda} &= \frac{1}{\lambda} \left[\sum_{i=1}^n y_i \right] - n - 0 \end{aligned}$$

Igualamos a 0 la expresión:

$$\frac{1}{\hat{\lambda}} \left[\sum_{i=1}^n y_i \right] - n = 0 \Rightarrow \hat{\lambda} = \frac{1}{n} \left[\sum_{i=1}^n y_i \right] = \bar{Y}$$

□

(Valor 25 puntos).

4. Problema 4

Sea Y una variable aleatoria que representa el número de éxitos en n intentos independientes con probabilidad p de éxito en cada intento. Además,

$$Y = \sum_{i=1}^n Y_i$$

donde

$$Y_i = \begin{cases} 1, & \text{si el } i\text{-ésimo intento resulta en éxito} \\ 0, & \text{en el otro caso} \end{cases}$$

para $i = 1, \dots, n$

1. a) Demuestre que $\hat{p}_n = \frac{Y}{n}$ es un estimador insesgado de p .

Solución. Tenemos las siguientes definiciones::

Definición 8.2 - Sesgo

Let $\hat{\theta}$ be a point estimator for a parameter θ . Then $\hat{\theta}$ is an unbiased estimator if $E(\hat{\theta}) = \theta$. If $E(\hat{\theta}) \neq \theta$, $\hat{\theta}$ is said to be biased.

Definición 8.3 - Sesgo

The bias of a point estimator $\hat{\theta}$ is given by $B(\hat{\theta}) = E(\hat{\theta}) - \theta$.

A probar: $E(\hat{p}_n) = p$. Entonces:

$$\begin{aligned} E(\hat{p}_n) &= E\left(\frac{Y}{n}\right) = \underbrace{\frac{1}{n}E(Y)}_{\text{Teorema 5.7}} = \frac{1}{n}E\left(\sum_{i=1}^n Y_i\right) = \frac{1}{n}E(Y_1 + Y_2 + \dots + Y_n) = \\ &= \frac{1}{n} \left[\underbrace{E(Y_1) + E(Y_2) + \dots + E(Y_n)}_{E(Y_i)=p, \text{ definición de valor esperado.}} \right] = \frac{1}{n} [p + p + \dots + p] = \frac{1}{n}(np) = p \end{aligned}$$

□

2. b) Demuestre que \hat{p}_n es un estimador consistente de p .

Solución. Procedemos a calcular la varianza del estimador, es decir:

$$VAR(\hat{p}_n) = \frac{pq}{n}, \quad q = (1 - p). \quad (\text{Deducción en el ejercicio 5.28}).$$

\Rightarrow Tomamos como referencia el teorema 9.1:

Teorema 9.1

An unbiased estimator $\hat{\theta}_n$ for θ is a consistent estimator of θ if

$$\lim_{n \rightarrow \infty} \text{VAR}(\hat{\theta}_n) = 0.$$

$$\implies \lim_{n \rightarrow \infty} \text{VAR}(\hat{p}_n) = \lim_{n \rightarrow \infty} \text{VAR}\left(\frac{pq}{n}\right) = \text{VAR}(0) = 0.$$

□

3. c) Cuando n es grande, demuestre que la distribución de $\frac{\hat{p}_n - p}{\sqrt{p(1-p)/n}}$ converge a una distribución normal estándar.

Solución. Considerando el teorema del límite central:

Teorema 7.4

Let Y_1, Y_2, \dots, Y_n be independent and identically distributed random variables with $E(Y_i) = \mu$ and $V(Y_i) = \sigma^2 < \infty$. Define

$$U_n = \frac{\sum_{i=1}^n Y_i - n\mu}{\sigma\sqrt{n}} = \frac{\bar{Y} - \mu}{\sigma/\sqrt{n}}.$$

Then, the distribution function U_n converges to the standard normal distribution function as $n \rightarrow \infty$.

Dados los 2 incisos anteriores tenemos $E(Y_i) = p$ y $\text{VAR}(Y_i) = p(1-p)$. Por hipótesis, sabemos $Y = \sum_{i=1}^n Y_i$. Definimos:

$$U_n = \frac{Y - np}{\sqrt{p(1-p)}\sqrt{n}} = \frac{\frac{Y - np}{n}}{\frac{\sqrt{p(1-p)}}{n}} = \frac{\hat{p}_n - p}{\sqrt{\frac{p(1-p)}{n}}}$$

Por lo tanto, la distribución converge a una distribución normal. □

4. d) Cuando n es grande, demuestre que la distribución de $\frac{\hat{p}_n - p}{\sqrt{\hat{p}_n(1-\hat{p}_n)/n}}$ converge a una distribución normal estándar.

Solución. Sabemos que \hat{p}_n es consistente, por lo que $(1 - \hat{p}_n)$ también debe ser consistente; por el inciso b del teorema 9.2, entonces $\hat{p}_n(1 - \hat{p}_n)$ es consistente para $p(1 - p)$.

$$\implies \frac{U_n}{W_n} = \frac{\hat{p}_n - p}{\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}} = \frac{\frac{\hat{p}_n - p}{\sqrt{\frac{p(1-p)}{n}}}}{\frac{\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}}{\sqrt{\frac{p(1-p)}{n}}}} = \frac{\underbrace{\frac{\hat{p}_n - p}{\sqrt{\frac{p(1-p)}{n}}}}_{\text{Inciso anterior.}}}{\underbrace{\sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{p(1-p)}}}_{\text{Su probabilidad converge a 1.}}}$$

Por lo tanto, U_n converge a una distribución normal y la probabilidad de W_n converge a 1. Considerando:

Teorema 9.3

Suppose that U_n has a distribution function that converges to a standard normal distribution function as $n \rightarrow \infty$. If W_n converges in probability to 1, then the distribution function of U_n/W_n converges to a standard normal distribution function.

Se concluye que la distribución U_n/W_n converge a una distribución normal estándar. \square

(Valor 25 puntos)

Referencias

Wackerly, D., Mendenhall, W., and Scheaffer, R. L. (2014). *Mathematical statistics with applications*. Cengage Learning.